

Hito 1: Alcance y viabilidad

Asignatura: Desarrollo y Despliegue de Soluciones Big Data
Máster Universitario en Big Data y Computación en la Nube
Curso académico 2025-2026

Alonso Marcos Muñoz (Alonso.Marcos@alu.uclm.es)

Jose Barros Ribademar (Jose.Barros1@alu.uclm.es)

Febrero de 2026

Datos de la entrega

Esta memoria t cnica se entrega en el marco de la asignatura Desarrollo y Despliegue de Soluciones Big Data, dentro del M ster Universitario en Big Data y Computaci n en la Nube, curso acad mico 2025-2026. El trabajo ha sido desarrollado por Alonso Marcos Mu oz y Jose Barros Ribademar durante febrero de 2026.

Introducci n del hito

El objetivo de este primer hito es cerrar el alcance del proyecto con una justificaci n t cnica y econ mica suficiente para sustentar su ejecuci n durante el resto de la asignatura. En esta fase no se plantea un prototipo parcial, sino una propuesta completa de trabajo que permita defender qu  problema de negocio se pretende resolver, por qu  una arquitectura de datos distribuida es adecuada y qu  condiciones de viabilidad deben cumplirse para que el proyecto sea defendible en t rminos acad micos y profesionales.

La memoria se ha redactado como documento de base para los siguientes hitos, de forma que cada decisi n tomada en febrero de 2026 quede trazada con su hip tesis asociada y pueda validarse posteriormente con resultados de implementaci n. La fecha oficial de cierre del hito es el 27 de febrero de 2026.

Alcance y viabilidad

Definici n del problema de negocio

La empresa de telecomunicaciones analizada gestiona una cartera activa de 2.000.000 de clientes particulares en un mercado muy competitivo. En el escenario de partida se observa una rotaci n mensual del 3%, equivalente a 60.000 bajas cada mes. Esta din mica refleja que las campa as generalistas de retenci n no est n siendo suficientes para priorizar a los clientes con mayor probabilidad de abandono y mayor impacto econ mico.

Desde el punto de vista financiero, el problema se concentra en dos frentes. Por un lado, se estima que 40.000 bajas mensuales son potencialmente recuperables y que cada cliente perdido supone, de media, 100 euros de margen neto anual no capturado. Por otro lado, la compa  a aplica descuentos de forma poco precisa sobre una parte de clientes que no presenta riesgo real de fuga, lo que incrementa el coste comercial sin retorno proporcional.

$$P rdida por fugas recuperables = 40.000 \times 100 = 4.000.000 \text{ EUR/mes}$$

$$\text{Coste por incentivos mal asignados} = 100.000 \times 10 = 1.000.000 \text{ EUR/mes}$$

$$\text{Impacto econ mico mensual estimado} = 5.000.000 \text{ EUR/mes}$$

Este volumen de p rdida justifica abordar el problema con una soluci n anal tica que permita identificar mejor el riesgo de churn y mejorar la asignaci n de incentivos.

An lisis y selecci n de la soluci n t cnica

Para resolver el caso se valoraron tres enfoques: reglas heur sticas, aprendizaje autom tico en entorno monol tico y arquitectura big data distribuida. El enfoque heur stico ofrece rapidez inicial, pero su mantenimiento crece de forma no lineal al aumentar la casu stica y sufre cuando cambian los patrones de comportamiento. El enfoque monol tico con machine learning mejora la capacidad predictiva, aunque introduce limitaciones de escalabilidad, de trazabilidad operativa y de incorporaci n de nuevas fuentes en escenarios de mayor volumen.

La alternativa distribuida, basada en un pipeline de datos en Databricks con arquitectura medallion, se selecciona porque se ajusta mejor al tamaño de la base de clientes, permite evolucionar el sistema por capas (bronze, silver y gold) y facilita la gobernanza técnica del proyecto. Esta decisión no se fundamenta en complejidad tecnológica por sí misma, sino en su adecuación al problema y en su coherencia con los objetivos formativos de la asignatura.

Evaluación de la viabilidad

La viabilidad técnica se considera favorable porque existe masa crítica de datos para entrenar y evaluar modelos de clasificación supervisada, el problema tiene una variable objetivo clara (baja/no baja), se dispone de señales explicativas relevantes y la ejecución en modo batch reduce el riesgo de implantación temprana.

En viabilidad económica se trabaja con hipótesis conservadoras: una reducción del 5% de fugas recuperables y del 5% de incentivos mal dirigidos. Bajo este supuesto, el beneficio mensual estimado es de 250.000 euros.

$$\text{Beneficio por mejora en fugas} = 4.000.000 \times 0,05 = 200.000 \text{ EUR/mes}$$

$$\text{Beneficio por mejora en incentivos} = 1.000.000 \times 0,05 = 50.000 \text{ EUR/mes}$$

$$\text{Beneficio total estimado} = 250.000 \text{ EUR/mes}$$

El coste mensual considerado es de 11.100 euros (10.000 de dedicación técnica y 1.100 de infraestructura cloud). Con estas cifras, el ROI mensual aproximado es del 2.152% y el payback estimado es de 1,3 días.

La viabilidad ética y legal incorpora criterios de cumplimiento alineados con RGPD: pseudonimización de identificadores, control de accesos a datasets sensibles, trazabilidad de datos y versiones de modelo, y evaluación de sesgo mediante métricas de equidad.

Planificación y recursos

Objetivos de negocio y traducción técnica

Los objetivos operativos para el proyecto son reducir en un 5% la pérdida asociada a fugas recuperables y reducir en un 5% el coste de incentivos innecesarios. Traducido a seguimiento mensual, implica pasar de 40.000 a 38.000 bajas recuperables y de 100.000 a 95.000 incentivos potencialmente mal asignados.

Organización del equipo

El trabajo se organiza en dos perfiles complementarios. Una parte se centra en ingeniería de datos y MLOps (ingesta, calidad, orquestación y trazabilidad), y la otra se orienta al modelado (construcción de variables, entrenamiento, evaluación y análisis de error).

Fuentes de datos y stack tecnológico

La solución se apoya en cuatro fuentes funcionales: maestro de clientes, histórico de bajas, registros de uso y facturación, e histórico de campañas con respuesta observada. El stack técnico previsto es Databricks y Delta Lake, procesamiento distribuido con Spark, modelado con Spark MLlib y seguimiento experimental con MLflow, manteniendo trazabilidad del desarrollo en GitHub.

Cronograma oficial del proyecto

El calendario de la asignatura se distribuye en cuatro hitos consecutivos: Hito 1 (24/02/2026-27/02/2026), Hito 2 (28/02/2026-20/03/2026), Hito 3 (21/03/2026-17/04/2026) y Hito 4 (18/04/2026-01/05/2026).

Cierre del hito

Con este hito queda definido un alcance t cnicamente consistente y econ micamente justificado para el proyecto de churn telco. La propuesta establece el problema de negocio, argumenta la elecci n arquitect nica, delimita condiciones de viabilidad y fija objetivos medibles para los siguientes entregables. El siguiente paso es ejecutar el Hito 2 con foco en preparaci n del dato, validaci n de calidad y materializaci n del pipeline medallion.